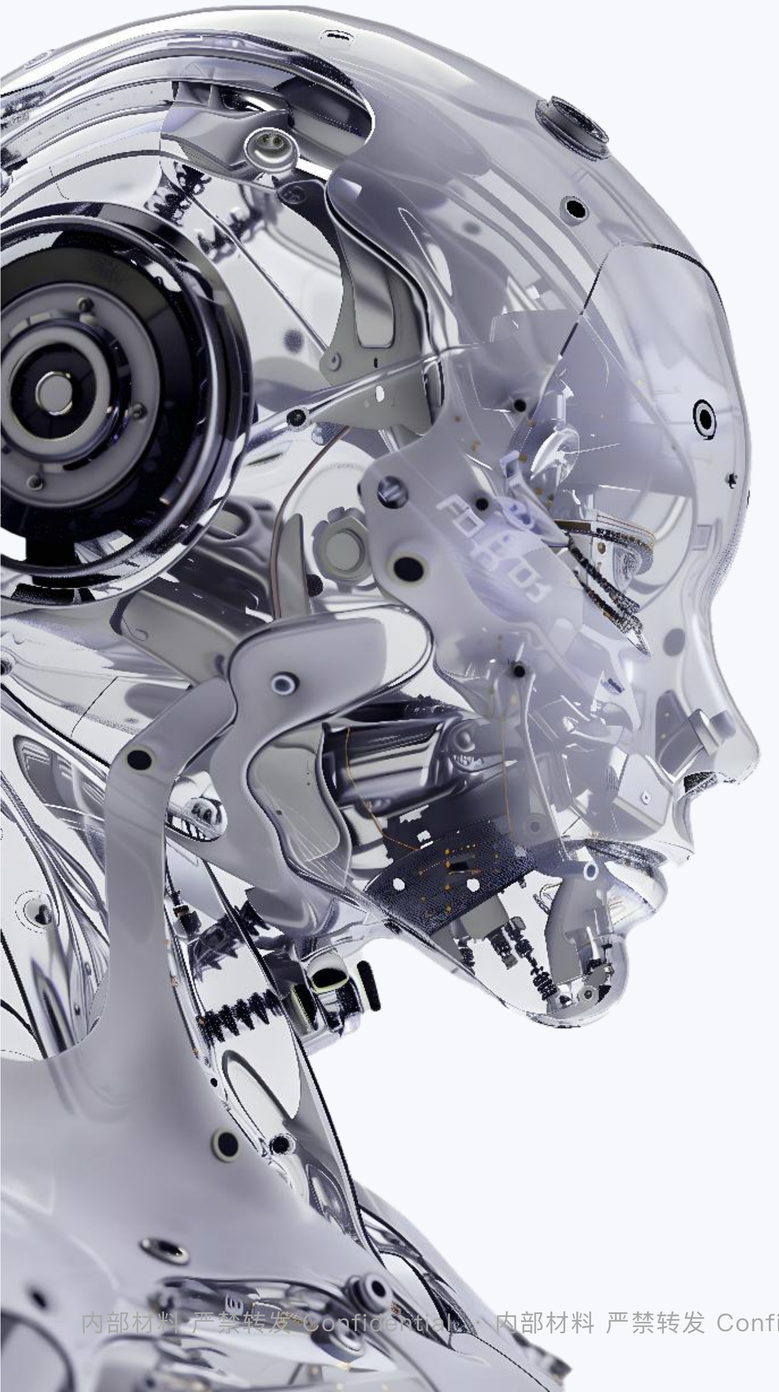


具身大脑的scaling law

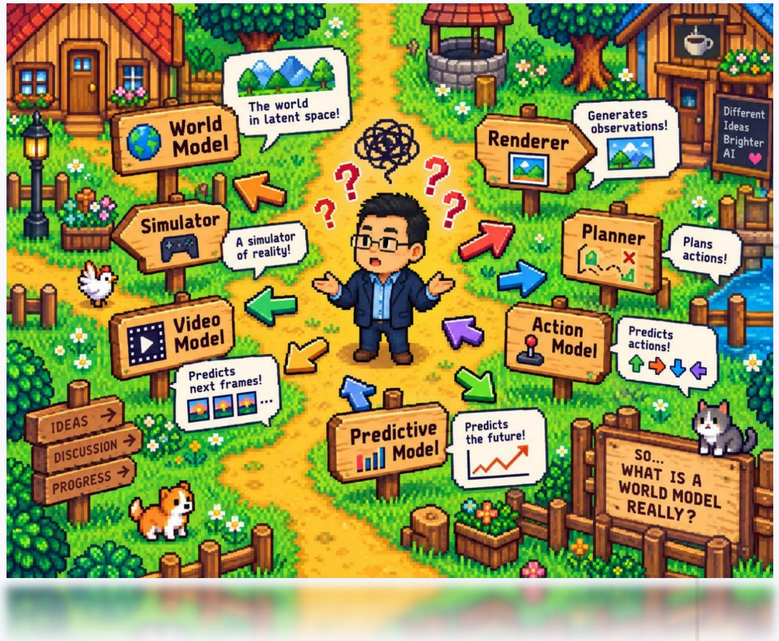
data scaling, model scaling, agentic scaling

王一舟 原力无限 CTO
高工人形机器人年会

2026/11

内部材料 严禁转发 Confidential · 内部材料 严禁转发 Confidential · 内部材料 严禁转发 Confidential · Confidential · 内部材料 严禁转发 Confidential · Confidential · 内部材料 严禁转发 Confidential

自我介绍



王一舟

原力无限 CTO

https://wangyizhou33.github.io/tech-blog/ （演讲材料）

wangyizhou3

具身智能是不是泡沫？这个问题问错了

原力无限

该问的是：技术进步能否在合理时间内、一步一步地变成商业价值

泡沫到底是什么？我的定义是：

泡沫 = 能力差距 × 弥合时间

能力差距：现在的技术能做到的，和人们期待它做到的之间的距离。

弥合时间：把这段距离走完需要多久。

只看能力差距是不够的。如果一个差距一年之内就能弥合，那它算不上泡沫。如果需要十年，那么在前五年里，它就是泡沫。原因在于资本有时间价值：第一年拿到的回报和第十年拿到的回报，即使名义金额一样，也不是同一笔回报。同样大小的能力差距，弥合时间越长，泡沫越大。

具身的三条 Scaling 线

Data Scaling（数据）
更大规模、更高质量、更覆盖长尾的数据，持续缩小能力差距

Model Scaling（模型）
更强的表征、推理与泛化能力，提升单位数据的能力增益

Deployment Scaling（落地）
更广的场景、更高的任务效率与可靠性，更快转化为可商业化的价值



所以，正确的问题不是“具身是不是被高估了”，而是：

当前的具身能力，能否在合理时间内产生有商业意义的价值？这份价值，是否与底层技术进步线性挂钩？

- “线性挂钩”指技术每进步一点，商业价值就跟着增加一点，而不是要等能力超过某个门槛才突然有价值。
- 两个条件都满足，就不是泡沫；有一个不满足，就是。

TORSO MODULE
OGNSIVENT
[ODSTEM2']
原力无限

Anthropic：机器人到底能做多少工作？

能力层面已接近 Proof of Concept，经济性仍是大规模落地瓶颈

我的长期观点

2026 年的具身智能，已经能在不少场景完成 Proof of Concept。
但要形成真正大规模商业闭环，还要同时满足两条：

- 任务 throughput > 人类熟练工
- 投资回收期 2–3 年

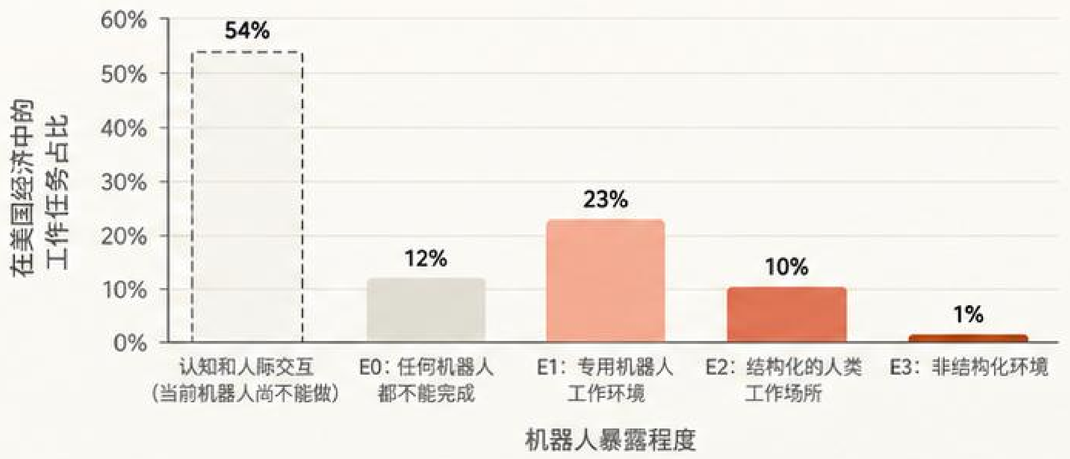
能做出来，不等于能算过账。

Anthropic 如何定义 task exposure

暴露程度	机器人可以完成的任务环境
E0	不能完成任务
E1	专用机器人工作环境（如工厂产线）
E2	结构化的人类工作场所（如物流仓）
E3	非结构化环境（如城市道路）

核心不是“能不能做”，而是“在多不受控的环境里能做”。

能力覆盖：机器人已能做约 3/4 的 physical work



74%
physical tasks 可由机器人在某些条件下完成

34%
对应美国经济中的全部工作时长占比

与 LLM 合并看，约 80%+ 的工作任务暴露于技术能力。

但经济性远未成立



0.3% 今天真正 cost-competitive 的 job tasks

≈40年 若机器人成本按历史约 3% / 年下降，要到约 10% 的工作具备成本竞争力

Anthropic 对未来的判断

- 最先受影响：已有机器人 foothold 的岗位，如 driving、warehouse packing
- 落地顺序：先结构化环境，再逐步走向开放环境
- 主要约束不只成本，还包括 capability、human preference、regulation
- 按历史趋势，机器人每年大约扩展到此前做不到的 physical work 的 2%

Source: Anthropic, What work can robots do? (Sep 30, 2026)

高质量营收：大脑公司的答案是部署

High-quality revenue comes from deployment

原力无限

具身的投资热度已经明显回落。行业里正在形成一个共识：靠融资讲故事的阶段过去了，接下来要看“高质量营收”。

什么样的营收算高质量？可以用一组对比来说明。

低质量的营收

- 一次性的项目制交付、演示订单、科研采购
- 每个项目都要单独投入工程人力
- 收入随人头线性增长
- 与模型本身的进步关系很弱
- 模型变强了，下一个项目仍然要从头做一遍

高质量的营收

- 可复制、可续费
- 随基座模型能力的进步而增长
- “基座模型”：用大量数据预训练、能用到很多场景的通用具身模型
- 技术进步会持续抬升商业价值

Unitree revenue mix

First 9 months of 2025 · per IPO prospectus



研究与教育 73.6%　其他 17.4%　工业部署 9%

宇树营收结构给出的信号：

即便是全球出货量领先的人形机器人公司，真正的工业部署收入占比仍然很低。

高质量营收的核心，不是展示，而是部署。

核心结论

高质量营收只有一个来源：不断开拓新场景，并在场景里部署。行业里常说“场景落地”，下文统称为 deployment：模型在真实客户场景里持续干活、持续产生收入。这里的“场景”，指一个具体客户的一类任务和环境。

PI 的答案：API 平台

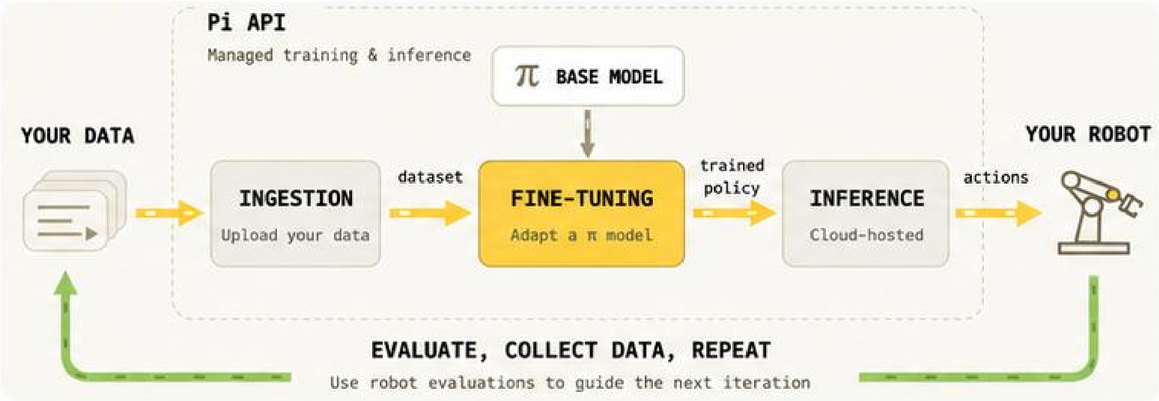
Pi's answer: an API platform

2026 年 10 月 13 日，PI 发布了 API beta。原文第一句是：

> *"We are making our latest models available for training and inference through the Pi API beta."*
>
> （我们通过 Pi API beta 开放最新模型的训练与推理。）

用法很直接：开发者上传自己的数据，在 PI 管理的算力上微调模型，再通过 PI 托管的网关调用微调后的模型，让机器人跑起来。这里的"微调"，指用目标场景的少量数据继续训练模型。

API workflow



PI 强调的闭环

- 上传数据 → 微调模型 → 托管推理 → 机器人执行
- 用评测结果指导下一轮迭代
- "use the failures to decide what data to collect next"

核心不是一次性训练，而是围绕真实部署持续采集失败案例、持续改进。

PI 的"部署"场景



PI 展示的并不是单一 demo，而是跨农业、餐饮、仓储、制造等多场景部署。

核心结论

PI 给出的答案不是卖单个机器人，而是做一个 **API 平台**：让客户上传数据、微调模型、调用推理，并在真实场景部署中形成数据闭环。
对大脑公司来说，**平台化 deployment** 就是高质量营收的一种雏形。

具身 Scaling 的三条线

原力无限

“Scaling”在大语言模型里几乎是一个口号：更多数据、更大模型、更多算力，能力就会稳定提升。
具身智能是否也有这样的规律，是这两年讨论最多的问题之一。

Scaling	增加的是什么	缩短的是什么
Data scaling	训练数据的规模、覆盖与来源	**能力差距**
Model scaling	模型容量；ICL；harness	**每个场景的适配时间；工作流对人工的依赖**
Deployment scaling	部署的场景数，以及参与部署的开发者数	**价值与技术进步之间的脱节**



三条线首尾相接，形成一个飞轮： 部署 → 目标场景数据 → 更强的基座模型 → 更低的适配成本、更可靠的工作流 → 更多部署

TORSO MODU
OGNSIVENT
(ODSTBM2)

原力无限

原力无限

训练范式：Pretraining vs Midtraining vs Posttraining

从通用先验，到具身操作，再到真实世界持续优化。

互联网图像数据
image / video / text



开源三方机器人遥操数据
public teleoperation / open datasets



高质量 egocentric manipulation data



domain-specific manipulation data



physical reinforcement learning



1 Pretraining
学习通用视觉表征、世界知识与基础 action prior

2 Midtraining
注入第一人称操作经验与任务/场景知识，对齐 manipulation 能力

3 Posttraining
在真实机器人上通过交互、奖励与回流数据持续提升成功率与泛化



3 Posttraining	真实世界交互数据，强化学习与回流数据 任务成功率、泛化能力最强
2 Midtraining	人类第一人称操作与特定场景数据 注入操作经验与任务知识，提升具身 manipulation 能力
1 Pretraining	互联网规模的图像/视频/文本数据 + 开源遥操数据 学习通用世界知识、视觉表征与基础 action prior

Takeaway

- Training recipe 不是单一阶段，而是分阶段吸收不同数据与反馈：Pretraining 学通用先验，Midtraining 学 manipulation 对齐，Posttraining 学真实世界中的持续优化。

TORSO MODULE
OGNSIVENT
(ODSTBM2)

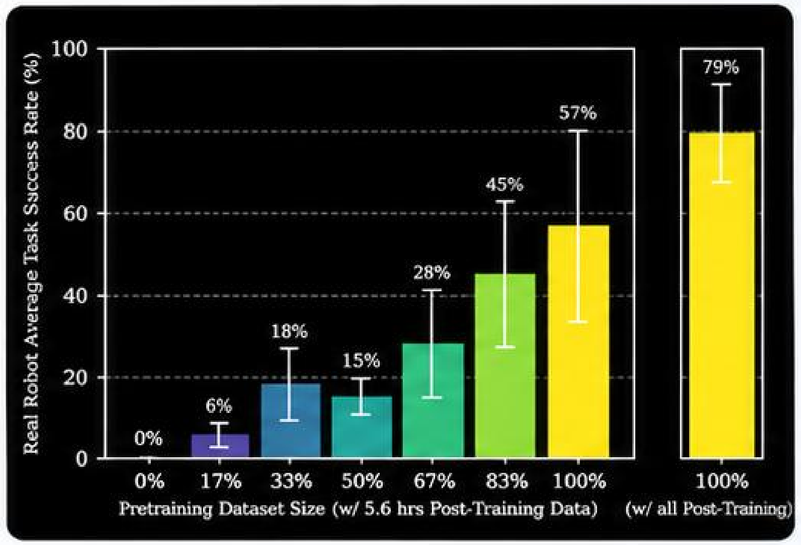
最显而易见的 Scaling：数据量，模型参数，算力

原力无限

具身智能也存在清晰的 scaling 规律：更多数据、更大的模型参数、更多算力，能稳定带来更好的能力。

数据量：

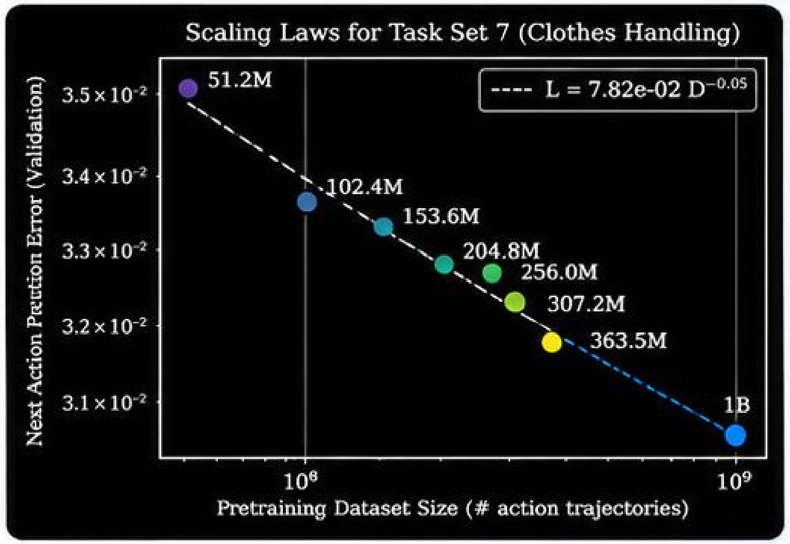
更大的预训练规模，带来更高的总体成功率



结论：在相同的 midtraining 数据预算下，预训练数据规模越大，总体任务成功率越高。

模型参数：

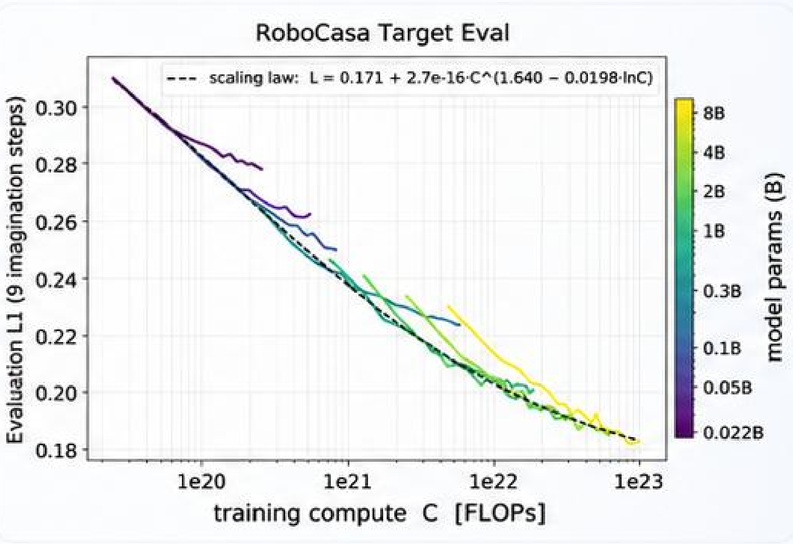
模型参数量同样呈现稳定的 scaling 规律



结论：随着模型参数量增大，下一步动作预测误差持续下降（当然，大参数量需要数据支撑）。

算力：

即使更换模型架构，性能依然随算力提升而稳定提升



结论：在 RoboJepa 模型的对比中，即使更换模型架构，评测性能依然随训练算力（FLOPs）的提升而稳定提高。

Takeaway | **数据量、模型参数、算力这三条最基础的 scaling 轴，在具身智能中同样成立，且彼此相互支撑。**

TORSO MODULE
OGNSIVENT
(ODSTBM2)

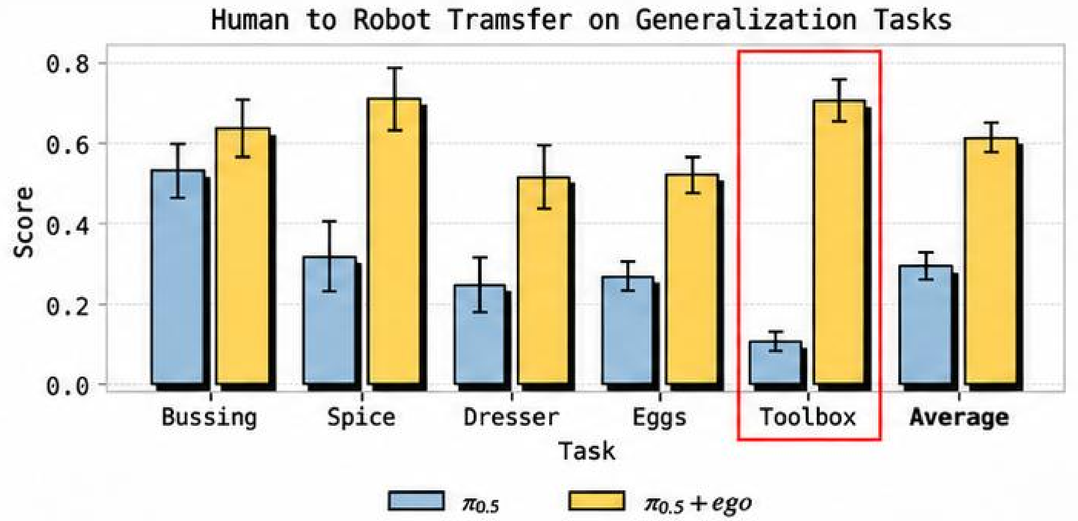
泛化性 Scaling

Human data improves generalization

原力无限

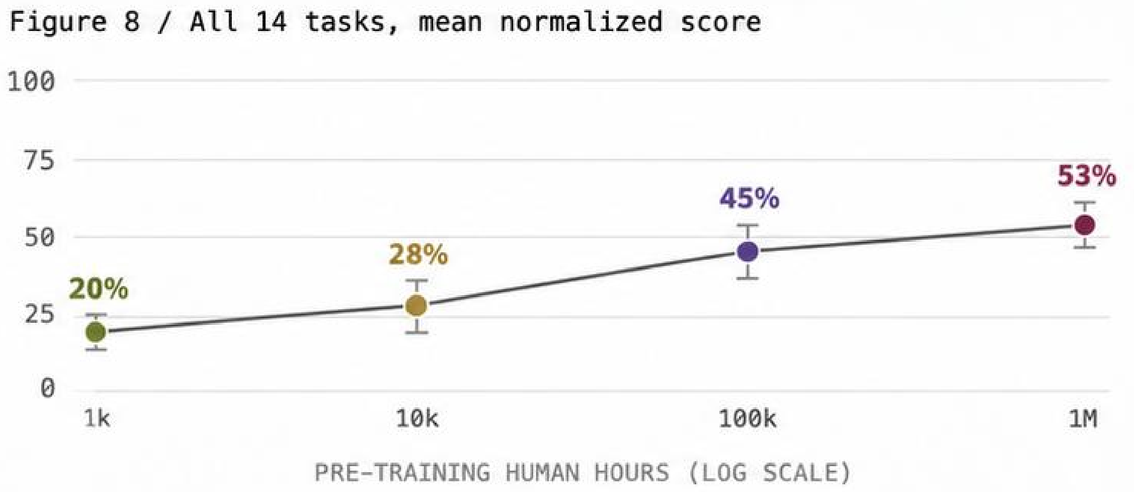
除了总成功率，另一个关键 scaling 维度是泛化性：模型是否能把 human data 里的操作经验迁移到机器人真实执行中。现有结果说明，human data 不仅有用，而且随着规模增长，泛化能力会继续提升。

PI 0.5：human data 帮助真实执行



- 所有任务上，黄色柱（π0.5 + ego）都高于蓝色柱（π0.5）
- 说明引入 human / egocentric data，有助于 human-to-robot transfer
- **结论：human data 能提升真实机器人执行与泛化**

Dyna 2.0：human data size 的 scaling



- 随着 pre-training human hours 从 1k 增长到 1M，平均分数从 20% 提升到 53%
- 不只是“有没有 human data”，而是 human data 的规模本身也带来收益
- **结论：泛化能力随 human data size 呈现 scaling 趋势**

Takeaway | **Generalization 也有 scaling：human data 不仅提升平均表现，还提升跨任务迁移；而且数据规模越大，泛化越强。**

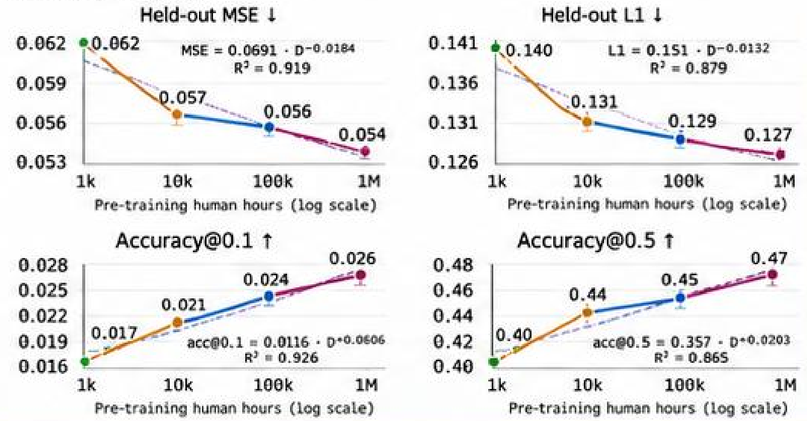
跨本体迁移（cross-embodiment gap）scaling

更多 human data、更多 robot data、更多 embodiment diversity，都在缩小跨本体迁移鸿沟

这里的 cross-embodiment gap，指模型在一种本体、数据来源或操作方式上学到的能力，迁移到另一种机器人本体时出现的性能损失。现有证据显示：无论是 human data 还是 robot teleop data，只要规模与多样性继续增加，这个 gap 都会被持续缩小。

1. Human data 训练、human data 评测

DYNA-2 / Figure 5



- pre-training human hours 从 1k 到 1M，Held-out MSE / L1 持续下降
- Accuracy@0.1 / Accuracy@0.5 持续上升
- **结论：更多 human data，表征与动作预测能力更强**

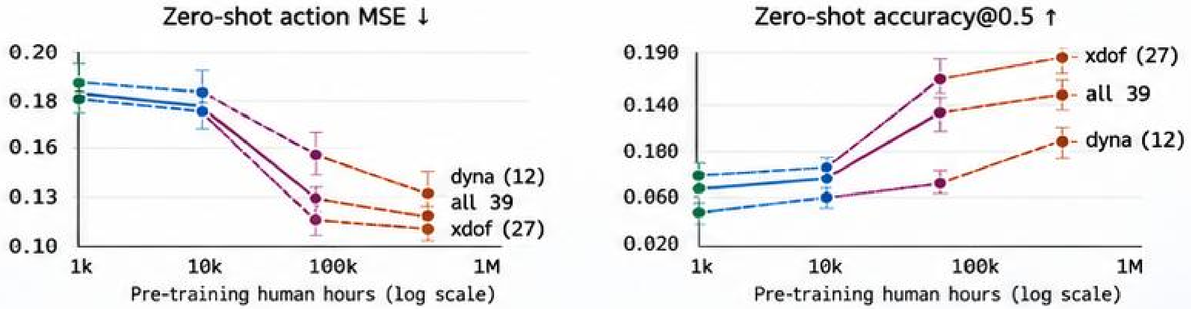
2. Robot teleop data：跨任务、跨场景、跨本体



- 真实遥操作数据覆盖多任务、多物体、多环境
- 为跨任务 / 跨场景 / 跨本体迁移提供更贴近执行端的数据基础
- **结论：robot data 是缩小 gap 的关键数据线**

3. Robot data scaling：zero-shot 指标同步变好

DYNA-2 / Figure 7



- 随着 pre-training human hours 增长，zero-shot action MSE 下降
- zero-shot accuracy@0.5 上升，dyna / all39 / xdof 均受益
- **结论：更多训练数据带来更强 zero-shot 泛化能力**

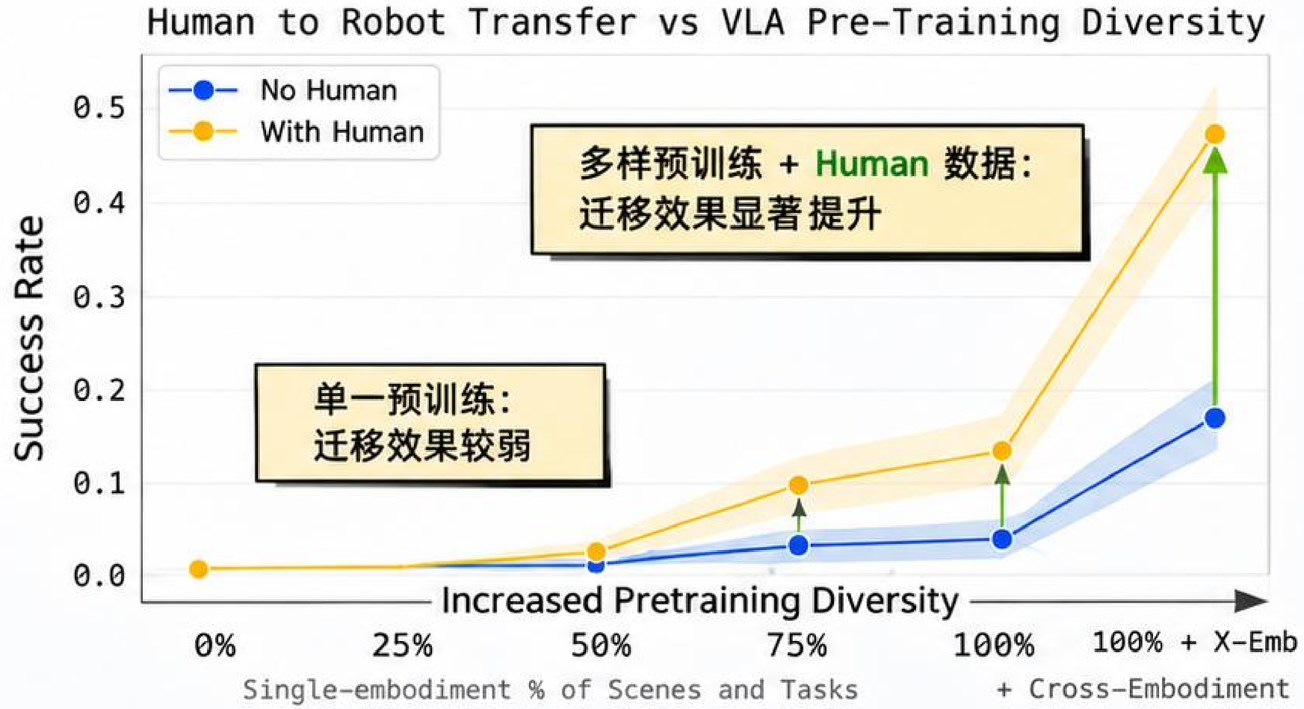
Takeaway cross-embodiment gap 也有 scaling：更多 human data、更多 robot teleop data，会持续提升迁移与 zero-shot 泛化能力。

跨本体迁移（cross-embodiment gap）scaling

更多 human data、更多 robot data、更多 embodiment diversity，都在缩小跨本体迁移鸿沟

跨本体迁移（cross-embodiment gap）：模型在一种本体上学到的能力，迁移到另一种机器人本体时出现的性能损失；
通过更丰富的跨本体与跨场景数据，能够显著提升 human → robot 的迁移效率与成功率。

多样的本体与数据，提升 human → robot 迁移效果



迁移性能随预训练多样性增长

加入更多跨本体、跨场景数据后，
成功率持续提升

Human 数据进一步放大增益

在相同数据规模下，加入 human data
后迁移效果显著更好

结论

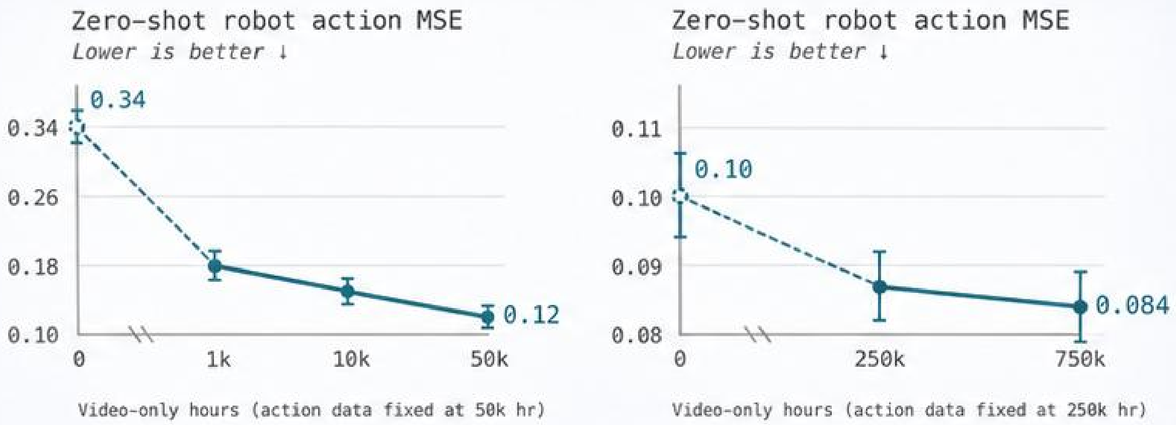
本体多样性 + human data
是缩小跨本体迁移鸿沟的关键

Takeaway 更多 embodiment diversity 与 human data，能够显著提升 human → robot 的迁移效率与成功率。

更深入的 data scaling

Video co-training 的规模收益显著；而 wrist observation 的边际收益有限

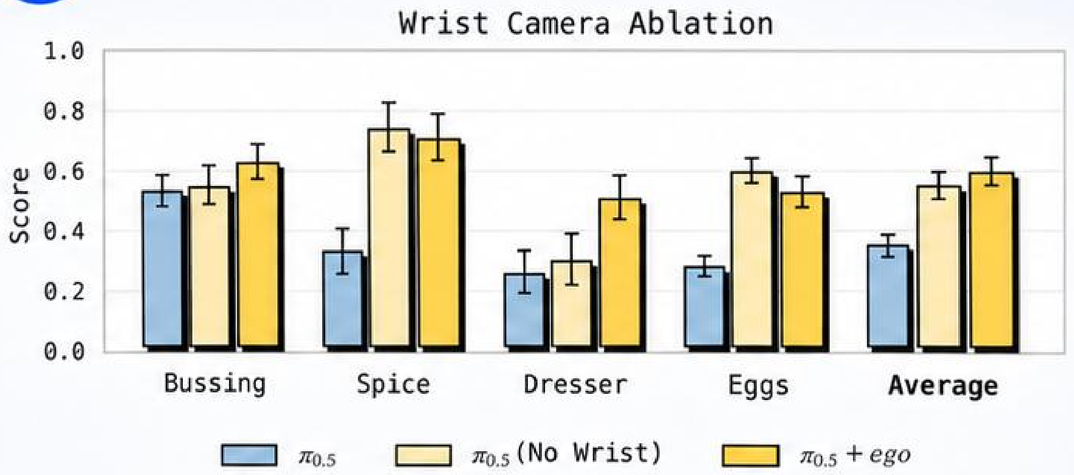
1. scale video data，泛化性能升明显



- 固定 human action data 预算，分别在 5 万小时与 25 万小时条件下，继续增加 video-only hours
- 随着 video data 增加，zero-shot robot action MSE 持续下降
- 在 5 万小时 action data 条件下，MSE 约从 0.34 降到 0.12
- 在 25 万小时 action data 条件下，MSE 约从 0.10 降到 0.084

结论：video co-training 是高杠杆的数据 scaling 路线，可显著提升泛化性能

2. wrist observation，增益有限



- 在 Bussing / Spice / Dresser / Eggs 等任务上，加入 egocentric 数据后性能明显提高
- 但仅比较 "有无 wrist camera"，平均性能差距并不大
- $\pi_{0.5}$ (No Wrist) 已经接近 $\pi_{0.5} + ego$ 的整体水平

结论：腕部观测并非最关键增益来源，其边际价值有限

Takeaway | 更深入地看 data scaling：并不是所有数据都同样值钱。大规模 video data 的共训练能显著提升泛化，而 wrist observation 的额外收益相对有限。

对数据金字塔的构成，我们能系统地设计了

A systematic view of the data pyramid composition

NVIDIA data pyramid

Real-World Data



Synthetic Data



Web Data & Human Videos



我们可系统设计的数据金字塔



数据的三条竞争力

设备决定“能不能规模采”， 场景决定“数据分布够不够真实广泛”，真值产线决定“数据能不能直接进入训练体系”。

01 设备产能

自研设备 + 三方设备接入，形成可复制采集能力









- 自研 Ego-Air 头戴式第一视角采集器
- 已接入头戴、腕部、手持夹爪等多种设备形态
- 统一时间同步、标注与数据格式
- 为规模化、多形态、可复制采集提供入口

采得到：规模化、多形态、可复制

02 场景产能

众包网络进入真实世界，覆盖多行业、多分布场景



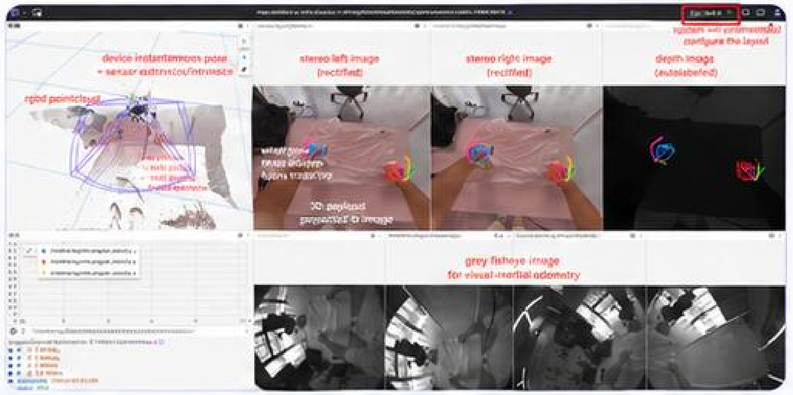


- 覆盖餐饮、零售、汽修、居家、家政与公共服务等场景
- 既有标准工位，也有非标准家庭与服务环境
- 场景不是“摆出来的”，而是在真实运营中持续采集
- 分布更真实、更有利于模型泛化

采得广、采得真

03 真值产线

从原始多模态数据到可训练真值





- 多视角同步：双目 / RGB / 深度 / 鱼眼
- 3D重建与定位：位姿、点云、深度与空间信息
- 自动与人工结合：手部骨架、投影、标注与审核
- 输出可训练数据、可视化结果与数据回流基础

处理得深、交付可训练

设备产能：采得到 | **场景产能：采得广、采得真** | **真值产线：处理得深、交付可训练** → **三者共同构成 DataGrid 的数据生产壁垒**

众包系统

让世界的真实动作，成为具身智能的数据

数据平台

数据接入、存储、处理与质检
沉淀高质量数据资产



数据有效性结算信息

质检结果、数据量、任务完成情况等

采集运营平台

任务发布、人员管理、进度监控与结算
连接客户需求与采集供给



四位一体
高效众包数据生产

上传数据

视频、传感器、动作轨迹等

发任务
结算

任务推送、进度跟踪、收益结算

采集设备

多形态采集设备，覆盖丰富场景
即插即用，稳定可靠



头环相机（第一视角）	数据手套（手部动作）	本体设备（遥操作）	灵巧手 / 夹爪（末端执行器）

监控

设备状态、采集进度
固件管理、远程运维

众包 App

采集任务接收、操作指引、数据上传与收益结算
让更多人轻松参与数据采集



更大规模的真实数据　更高效的众包运营　更可靠的数据质量

两类核心数据源：Ego 数据 + 大脑训练场内数据

以 AI Infra 为底座，面向具身智能构建双轨驱动的数据采集与训练闭环： 一类是可规模化覆盖多场景的 Ego-centric 数据，另一类是围绕模型失败分布持续迭代的大脑训练场内数据。

01 Ego-centric 数据

以第一人称数据为核心，覆盖 Ego / UMI / 触觉手套 / 真机等多种形态，是可规模化获取的通用数据源。



- 以第一人称采据为核心，覆盖 Ego / UMI / 触觉手套 / 真机等多种形态。
- 依托 AI Infra、采集管理平台和数据处理平台，形成从采集、清洗、真值生成到模型训练与部署的闭环。
- 适合覆盖家庭、办公、工业制造、商超、仓储物流、户外等丰富场景。
- **优势**：规模化、低成本、场景丰富，适合预训练与数据微调。

众包网络 多模态终端
Ego / UMI / 触觉手套等

海量小时级 数据产出
500万小时/年 参考

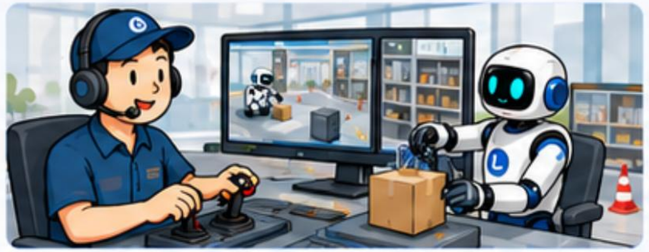
多场景 持续采集
家庭 / 办公 / 工业 / 商超 / 仓储 / 户外等

02 大脑训练场内数据

同样是真机场地，但不再只是传统遥操作数采，而是围绕模型当前失败分布进行数据生产，包含实景遥操作与规模化真机强化学习两类高价值数据。

实景遥操作

由采集员或专家在真实场景中遥操作机器人，获取高质量示范数据。



场景脚本



（观察，动作）数据单元



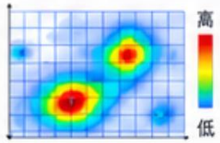
- 由采集员或专家在真实场景中遥操作机器人，获得高质量示范数据。
- 数据单元以（观察，动作）为主，适合冷启动、动作先验与特定任务示教。
- 适用于复杂操作、长尾任务与特定技能采集。

规模化真机强化学习 / 脑训练中心

客户模型自主运行，人只在失败点接管并示范纠正，围绕失败分布持续生产数据。



模型当前失败分布

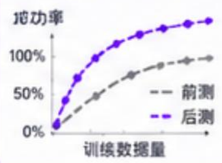


失败收集为资产



资产 / 负向信号

前测 → 后测



- 客户模型自主运行，人只在失败点接管并示范纠正。
- 数据单元更丰富：观察、动作、成功/失败、接管点、专家纠正轨迹。
- 由模型当前失败分布决定下一轮该补什么数据，实现有的放矢。
- 支持在线交互、失败资产化、前测/后测与持续迭代。



Ego 数据：广覆盖、低成本、强规模化
多场景、多形态、海量数据，支撑模型预训练与数据微调洵。

双数据源共同支撑具身大脑训练

场内数据：高价值、强反馈、驱动模型持续进化
围绕失败分布，持续生产高价值数据，加速模型能力提升。

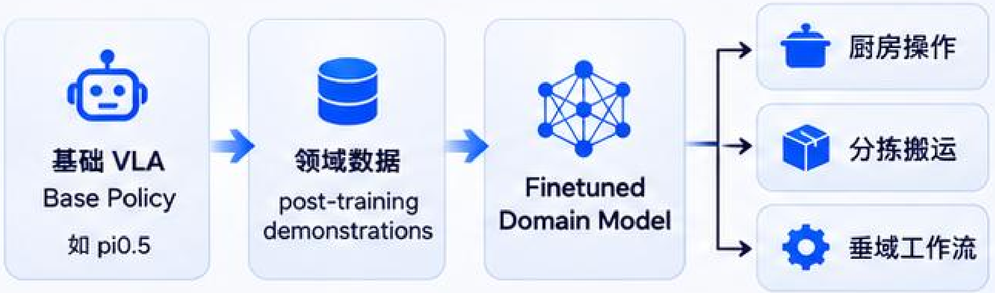


Finetuning vs In-Context Learning

任务适配的位置，正在从“模型权重”迁移到“上下文示范”。

Finetuning（权重适配）

以 pi0.5 及其衍生垂域应用模型为代表



- 任务知识主要写入模型权重
- 适配新任务通常需要新增示教 / finetuning
- 适合稳定、可重复的垂域落地

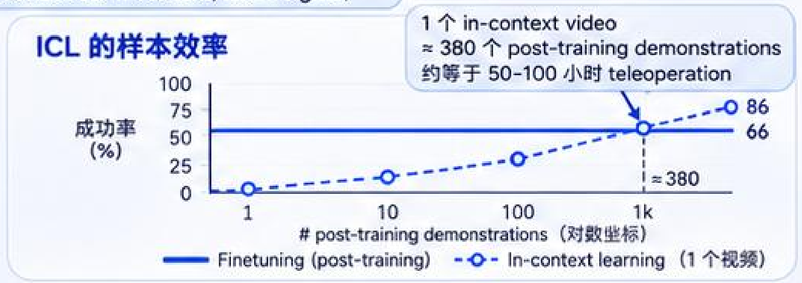
像 BERT 时代：通过改权重来适配任务

In-Context Learning（上下文适配）

以 Skild AI 与 Generalist Robotics 的 ICL 方法为代表



- 任务知识临时写入上下文，而非权重
- 可通过示范视频快速适配未见任务
- 更像 ChatGPT 时代：通过 prompt / context 适配任务



BERT → ChatGPT 的变化，在具身里对应：Finetuning → In-Context Learning

Takeaway： Finetuning 把任务写进权重，ICL 把任务写进上下文。对具身智能而言，ICL 有望像语言模型一样，提高新任务适配效率，并显著减少昂贵的 post-training / teleop 需求。

泛化性 (generalization) scaling

原力无限

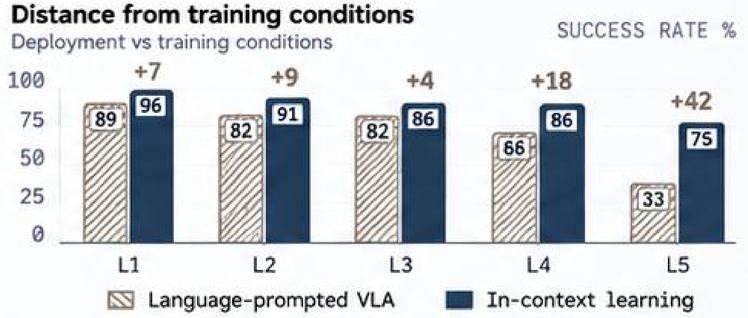
除了平均成功率，另一个关键 scaling 维度是泛化性：预训练规模越大，ICL 在分布外任务上的收益越明显；而当部署条件偏离训练分布时，ICL 的退化也更小。

1. 预训练越多，OOD 泛化收益更强



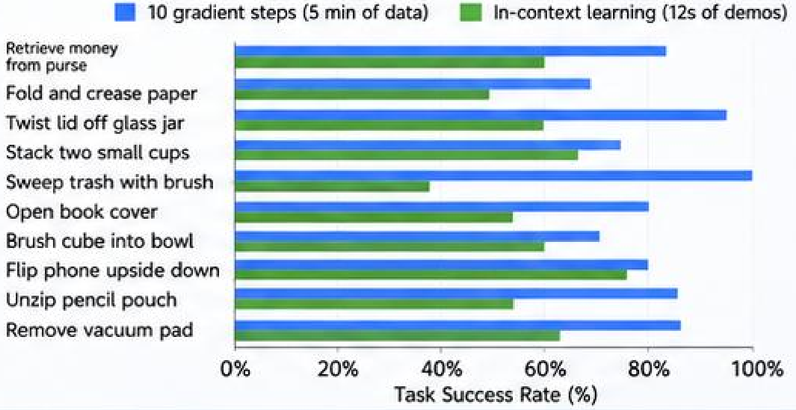
- 预训练数据越多，Seen tasks 与 Unseen tasks 都提升
- ID 场景下，两种方法差距较小
- OOD 场景下，ICL 的数据规模收益明显更强

2. 场景越偏离训练分布，ICL 掉点更小



- 控制数据量后，ICL 在 L1–L5 都优于 language-prompted VLA
- 随着 deployment 与训练条件距离增大，ICL 相对优势扩大
- 结论：ICL 对 distribution shift 更稳健

3. ICL + 少量 finetuning，提升明显



- 仅 12 秒 demo 的 ICL 已具备不错表现
- 再加 10 gradient steps（约 5 分钟数据），大多数任务显著提升
- 结论：ICL 可作为快速适配起点，少量 finetuning 进一步放大收益

Takeaway

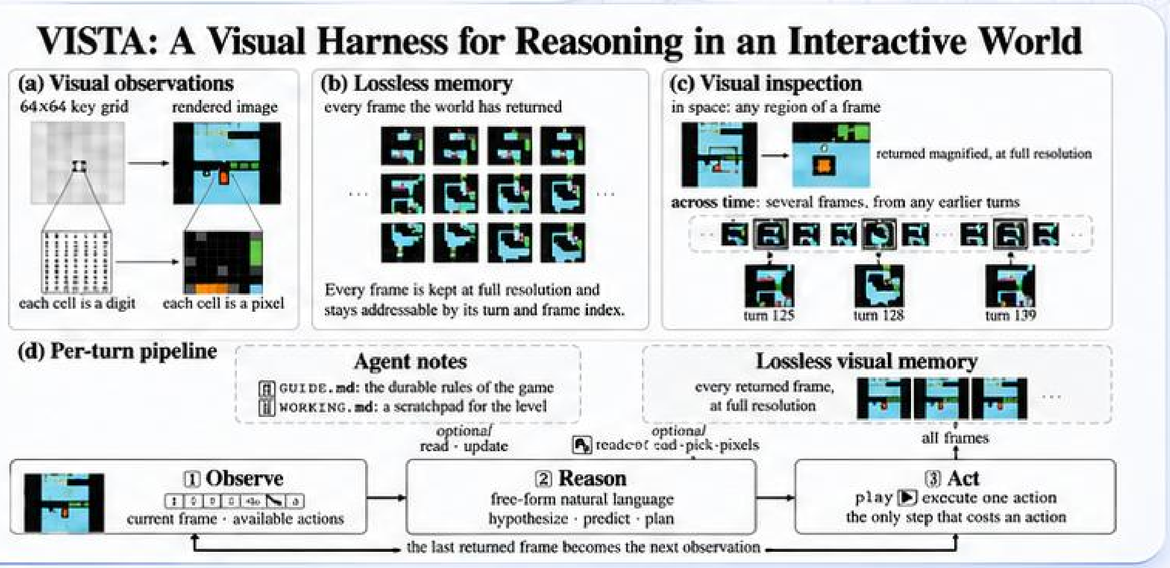
Generalization 也有 scaling：更多 pretraining 让 ICL 在 OOD 上收益更大；面对更远的 deployment shift，ICL 更稳；再结合少量 finetuning，可快速把性能推高。

LLM + Agentic 系统直接部署在具身智能

在 Robo-Coliseum 榜单上，多个 frontier LLM 直接出现在具身任务排名中，说明也可以通直接部署到具身系统。

Overall | Instruction Following | Spatial Reasoning | Robustness | General Manipulation | Protocol →

Rank	Account	Model	Total Score	Instruction Following	Spatial Reasoning	Robustness	General Manipulation	Open Source
1	Primotion	Paimon	0.7754	0.8961	0.6791	0.8653	0.6613	
2	HiDream.ai	HiDream-O1-Embodied	0.7692	0.8913	0.7437	0.7978	0.6442	
3	Claude Opus 5.5	Claude Opus 5.5	0.7628	0.9660	0.8250	0.7930	0.4670	
4	GPT-6 Astra	GPT-6 Astra	0.7599	0.9935	0.7833	0.8042	0.4586	
5	GPT-6.1 Sol	GPT-6.1 Sol	0.7090	0.9550	0.7771	0.7040	0.4001	
6	Dexmal	DM0.5	0.7076	0.8444	0.6146	0.7344	0.6370	View
7	Gemini 4 Argon	Gemini 4 Argon	0.6685	0.8589	0.6938	0.7336	0.3879	
8	GigaAI	GigaBrain-0.7	0.6504	0.8166	0.4729	0.6800	0.6320	View



1 Code-as-Policy

LLM 主要扮演 coding agent 的角色

自然语言指令
“把桌上的杯子放到咖啡机下方”
→ LLM
→ 生成代码 / program / plan

```
# generated by LLM
move_to(cup)
grasp()
move_to(coffee_machine)
place()
```

→ Tool / Robot API 调用 → 执行

- LLM 负责把任务翻译成可执行代码
- 代码中显式调用 tool / robot API
- 适合结构清晰、接口稳定的任务

VS

2 Harness

由 Agent 系统根据模型 response 来调用 tool

自然语言指令
“把桌上的杯子放到咖啡机下方”
→ LLM response
→ Agent Harness
- Prompt（任务描述）
- Toolcall（工具调用）
- Skill（技能库）
- Context Management（上下文管理）
- Multi-agent Loop（多智能体协同）
- Guardrail（安全约束）

→ Tool / Robot API 调用 → 执行

- 模型给出意图、步骤或中间响应
- Agent 系统负责工具调用与上下文管理
- 适合复杂流程、长任务与多技能协同

Takeaway： frontier LLM 进入具身榜单，并不意味着都要训练成专用 policy。现实中常见的两条路径是：Code-as-Policy（LLM→code→toolcall）和 Harness（LLM response→agent system→toolcall）。

原力无限

小脑平台 vs 大脑平台

两类平台分别面向动作技能生产与通用任务智能生产，但都服务于模型到本体 / 场景的持续部署。

小脑平台

动作视频 → 小脑模型 → 动作编排 → 本体 OTA

人类动作视频 / 资产库 → 小脑模型生产 → 动作编排 / 技能库 → 模型至本体 OTA

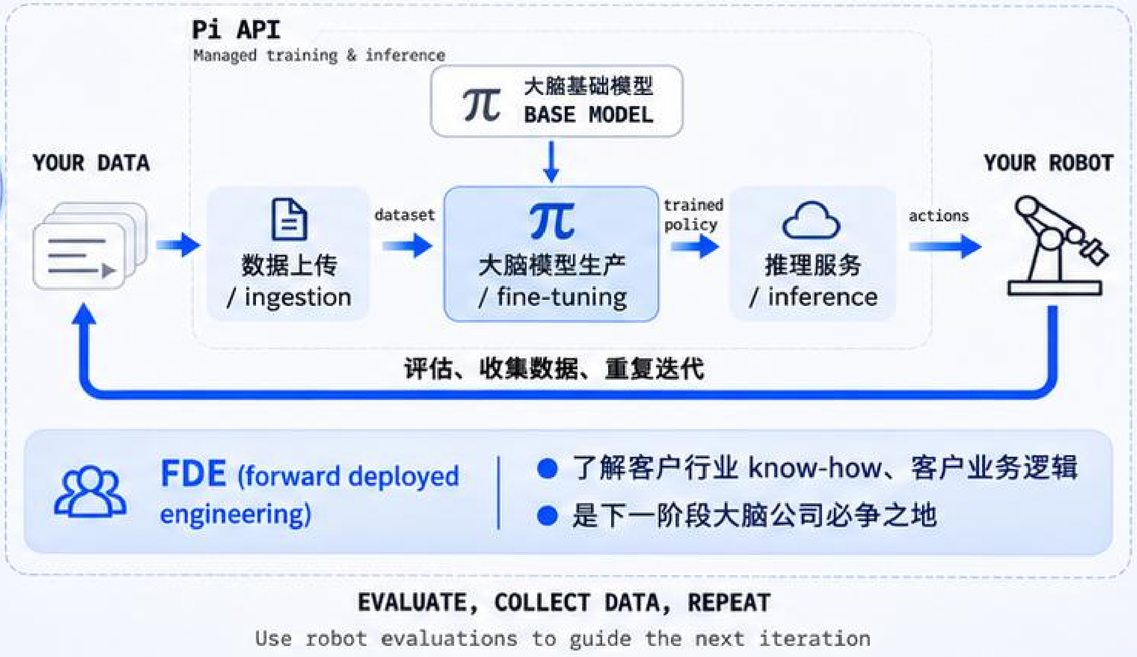


- 面向 locomotion / manipulation 等动作技能
- 强调 motion imitation、技能复用与编排
- 最终部署到具体本体，形成可执行的小脑能力

VS

大脑平台

数据上传 → 大脑模型 → 场景部署



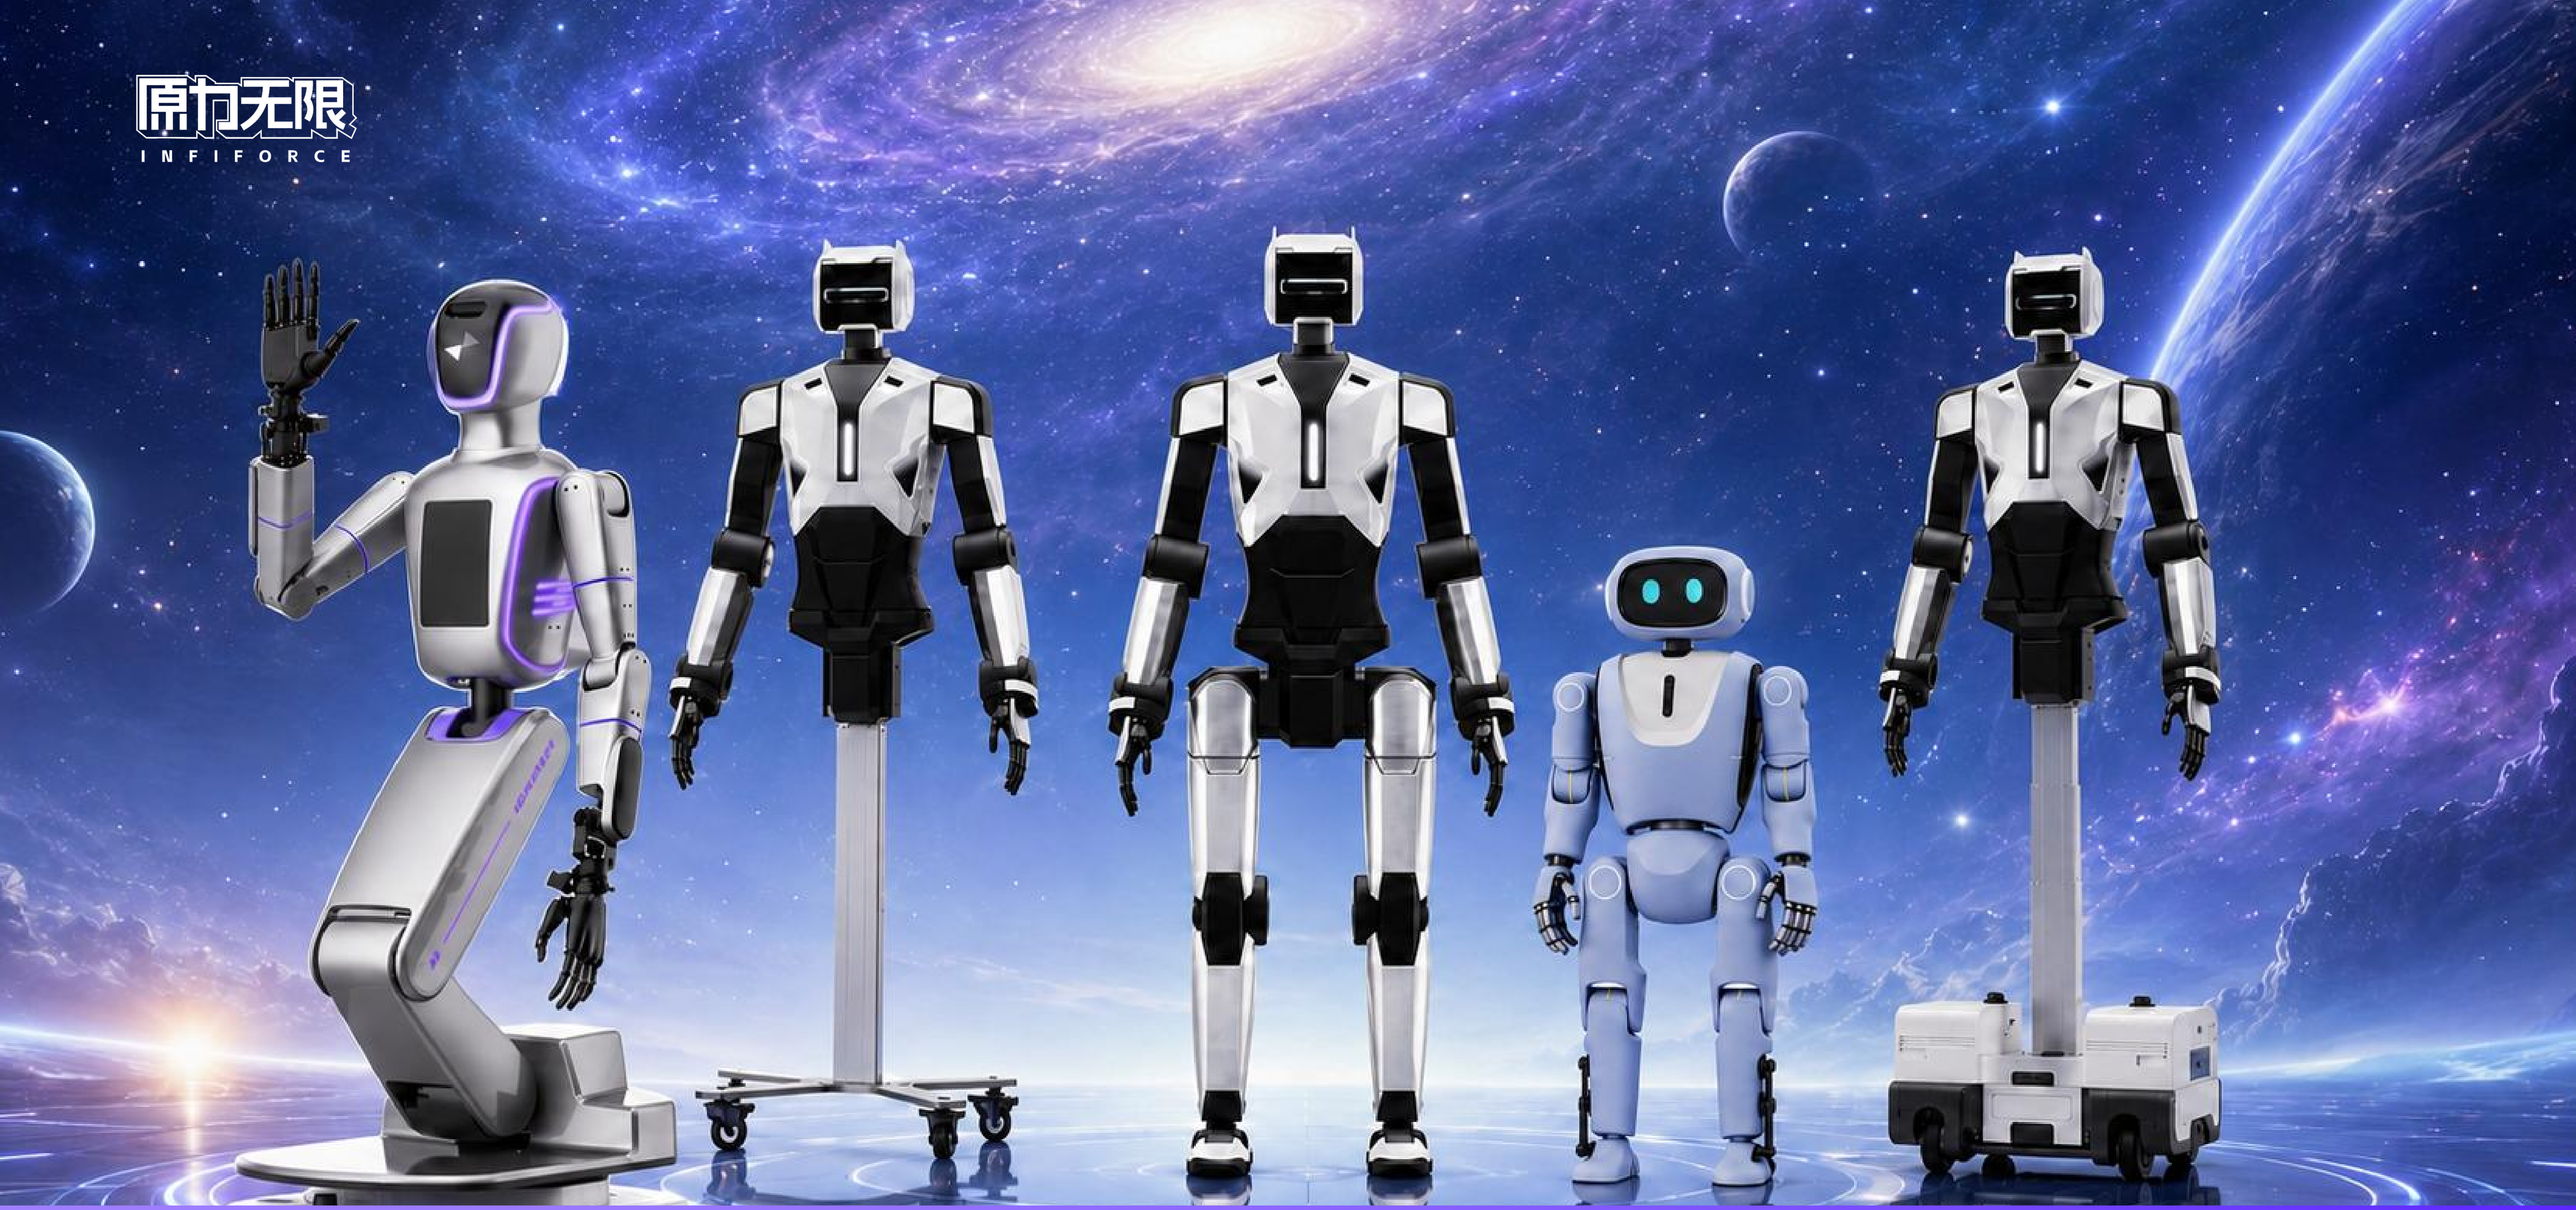
FDE (forward deployed engineering)

- 了解客户行业 know-how、客户业务逻辑
- 是下一阶段大脑公司必争之地

EVALUATE, COLLECT DATA, REPEAT

Use robot evaluations to guide the next iteration

Takeaway | 行业小脑平台已经成熟，且门槛较低。大脑平台由 physical intelligence 跨出第一步，给了人想象空间



官方网站：www.infiforce.cn
官方邮箱：info@infiforce.cn
集团总部：杭州余杭阿里巴巴数字生态创新园

官方公众号

官方视频号